pesikj Rok 2024 last month

1367 lines (1367 loc) · 1.65 MB

Preview Code Blame Raw

Lekce 7

Rozhodovací stromy jou dalším z algoritmů, které můžeme používat ke klasifikaci. Jejich obrovskou výhodou je, že jsou velmi snadno interpretovatelné. To znamená, že uživatel může snadno zjistit, proč algoritmus přiřadil záznam k dané skupině.

Scikit-learn umí graf exportovat ve formátu aplikace Graphviz. Pro ni pak existuje modul, který umí vykreslit rozhodovací strom jak obrázek.

- Nejprve je potřeba stáhnout software Graphviz zde.
- Následně je potřeba nainstalovat modul `pydotplus` příkazem `pip install pydotplus` .

In [84]:
```
import pandas
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import ConfusionMatrixDisplay, accuracy_score, precision
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.preprocessing import OneHotEncoder
from sklearn.tree import export_graphviz
from six import StringIO
from IPython.display import Image
import pydotplus
```

Popis importů

- `DecisionTreeClassifier` - klasifikátor využívající algoritmus rozhodovacího strumu, dokumentace je zde
- `ConfusionMatrixDisplay` - vizualizace matice záměn, dokumentace je zde
- `accuracy_score` , `precision_score` a `recall_score` - funkce pro vyhodnocení výsledků modelu, dokumentace je zde
- `train_test_split` - funkce pro rozdělení dat na trénovací a testovací, dokumentace je zde
- `GridSearchCV` hledá nejlepší parametry klasifikátoru ze zadaného rozsahu podle zadané metriky, dokumentace je zde
- `export_graphviz` je funkce pro export rozhodovacího stromu do DOT (software Graphviz) formátu, dokumentace je zde
- `StringIO` je objekt, který umožňuje uložení dat do paměti, je s nimi možné pracovat podobně jako se souborem, je přímo součástí jazyka Python, dokumentace je zde.
- `Image` je objekt, který umožní zobrazit data jako obrázek
- `pydotplus` je modul pro komunikaci se software Graphviz (např. vygenerování obrázku), dokumentace je zde

In [85]:
```
import os
os.environ["PATH"] += os.pathsep + r'C:\Program Files\Graphviz\bin'
```

Budeme pracovat s daty v souboru titanic.csv, která obsahují data o pasažérech

Budeme pracovat s daty v souboru titanic.csv, která obsahují data o pasažérech Titanicu. Náš model bude predikovat, jestli pasažér(ka) potopení Titanicu přežil(a).

In [86]:
```
data = pandas.read_csv("titanic.csv")
data.head()
```

Out[86]:

	sex	age	sibsp	parch	fare	embarked	class	who	alone	survived
0	male	22.0	1	0	7.2500	S	Third	man	False	0
1	female	38.0	1	0	71.2833	C	First	woman	False	1
2	female	26.0	0	0	7.9250	S	Third	woman	True	1
3	female	35.0	1	0	53.1000	S	First	woman	False	1
4	male	35.0	0	0	8.0500	S	Third	man	True	0

Aby náš první strom byl co nejjenodušší, budeme pasažéry rozdělovat pouze podle pohlaví. Do tabulky `X` tedy vložíme pouze sloupec `sex` a do série `y` sloupec `survived`.

In [87]:
```
feature_cols = ["sex"]

X = data[feature_cols]
y = data["survived"]
```

Rozhodovací strom si sám o sobě neporadí s textovými zápisy pohlaví, využijeme proto `OneHotEncoder`. Výsledek převedeme na typ pole (`array`) pomocí metody `toarray()`, abychom si mohli prohlédnout výsledek. Pole je základní datovou strukturou, která je převzatá z modulu `numpy`. Na rozdíl od tabulky v `pandas` je pole poněkud jednodušší strukturou - například neobsahuje index, nepodporuje dotazy a nejde přímo uložit do souboru. Díky jejich jednoduchosti je však práce s nimi rychlejší.

Podívejme se nyní na obsah pole `X`. Vidíme, že vy výstupu máme dva sloupce. V každém řádku najdeme vždy jednu hodnotu 0.0 a jednu hodnotu 1.0. Pořadí závisí na tom, jestli je daná osoba muž nebo žena.

In [88]:
```
encoder = OneHotEncoder()
X = encoder.fit_transform(X)
X = X.toarray()
X
```

Out[88]:
```
array([[0., 1.],
       [1., 0.],
       [1., 0.],
       ...,
       [1., 0.],
       [0., 1.],
       [0., 1.]])
```

Pole nemá názvy sloupečků. Pokud bychom je ale potřebovali, můžeme je zjistit z proměnné `encoder`, a to pomocí metody `get_feature_names_out()`.

In [89]:

```
encoder.get_feature_names_out()
```

Out[89]:
```
array(['sex_female', 'sex_male'], dtype=object)
```

Data si na testovací a trénovací sadu rozdělíme ručně, protože nevyužíváme `GridSearchCV`.

In [90]:
```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, rand
```

Dále vytvoříme `DecisionTreeClassifier`, což je klasifikátor využívající algoritmus rozhodovacího stromu. Necháme nastavené výchozí parametry.

In [91]:
```
clf = DecisionTreeClassifier()
clf = clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)
```

Dále vygenerujeme grafický výstup. Využijeme funkci `export_graphviz`. Abychom si obrázek mohli prohlédnout Jupyter notebooku, využijeme následující příkazy. Výsledkem je obrázek, který se zobrazí v Jupyter notebooku.

In [92]:
```
# Vytvoření objektu StringIO, který je jakousi "virtuální" souborovou struktu
# Tento objekt bude použit pro ukládání struktury rozhodovacího stromu.
dot_data = StringIO()
# Funkce export_graphviz z knihovny sklearn se používá pro konverzi rozhodova
# do DOT formátu, což je grafický jazyk používaný pro popis grafů a stromů. P
# kam se výsledek uloží - v tomto případě do naší StringIO instance dot_data.
# že uzly stromu budou vyplněny barvou, což může pomoci vizualizovat hodnoty
export_graphviz(clf, out_file=dot_data, filled=True)
# Tento řádek kódu používá knihovnu pydotplus k převedení DOT dat do formátu,
# Metoda getvalue() naší instance StringIO (dot_data) se používá pro získání
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
# Tento poslední řádek vytváří obrázek stromu ve formátu PNG. Funkce Image po
# a slouží pro zobrazení obrázku přímo v notebooku Jupyter. Metoda create_png
Image(graph.create_png())
```

Out[92]:

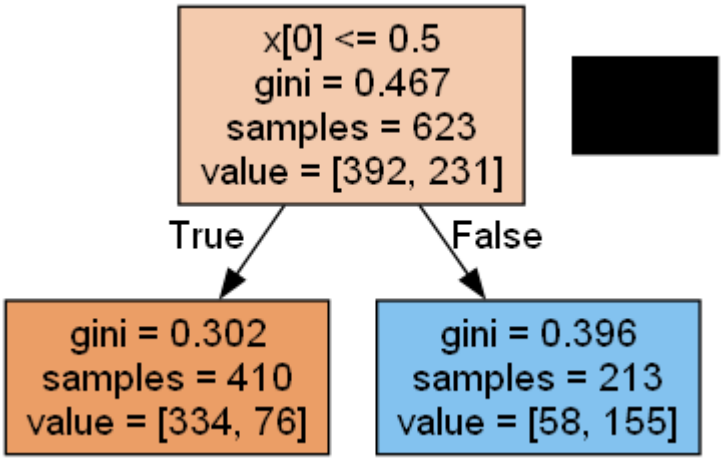

Pokud Jupyter notebooku nepoužíváme nebo pokud chceme uložit strom jako obrázek (např. pro vložení do blogového článku), příkaz upravíme. Použijeme metodu `write_png()` a jako parametr zadáme jméno souboru, kam chceme obrázek uložit. Přípona souboru by měla být `.png`, což je oblíbený grafický formát pro ukládání

obrázků.

In [93]:
```
dot_data = StringIO()
export_graphviz(clf, out_file=dot_data, filled=True)
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
graph.write_png('tree.png')
```

Out[93]: True

Označení "strom" vychází z části matematiky, která se nazývá teorie grafů. My se jí zabývat nebudeme, ale popíšeme si jeho strukturu a pojmy, které se k jejímu popisu používají.

Nahoře je tzv. vrchol, z něhož vychází dvě hrany. Tento vrchol má dva potomoky. Ti sami už žádné potomky nemají, vrcholy bez potomků pak značujeme jako listy. Každý z vrcholů (kromě listů) je místem, kde se musíme rozhodnout, kterou z hran budeme pokračovat.

Jednotlivé typy uzlů jsou shrnuty na obrázku níže. Máme tam:

- root node (kořen),
- decision node (rozhodovací vrchol),
- leaf (list).

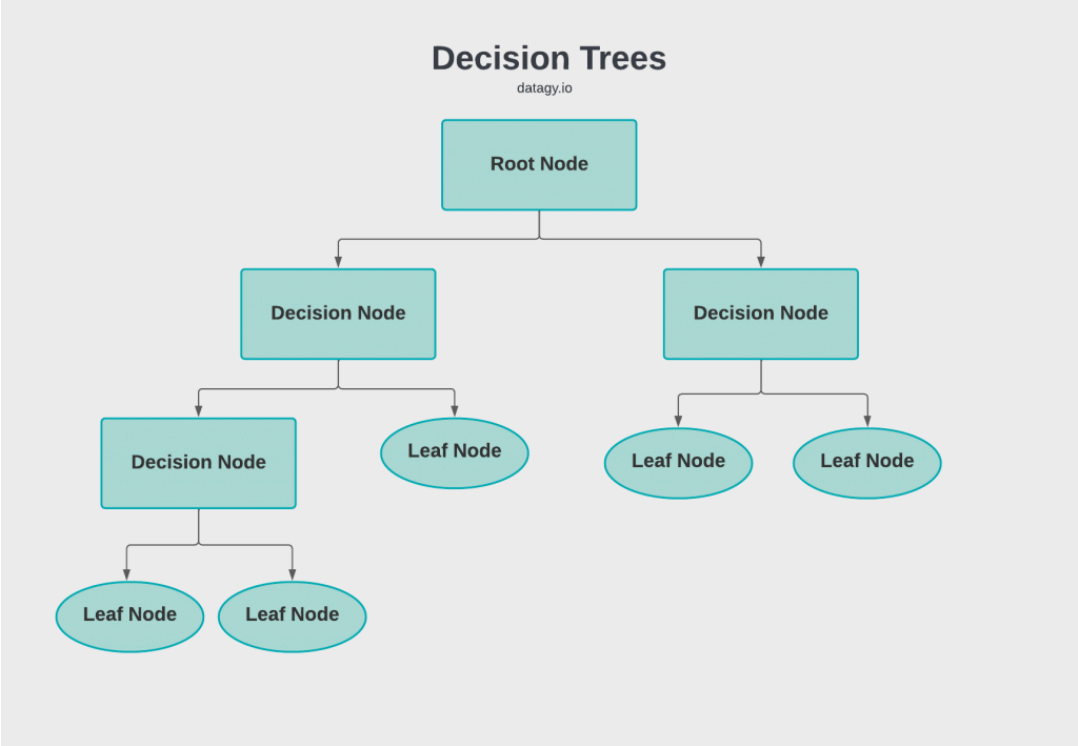

Rozhodnutí provádíme na základě záznamů, který chceme klasifikovat. V našem případě se rozhodnujeme pouze na základě pohlaví (nic dalšího v datech nemáme). Rozhodujeme se podle prvního řádku popisu uzlu. Zde je ale dost tajemný výraz `X[0] <= 0.5` . Abychom zjistili, co tento výraz znamená, doplnímu do grafu popisku sloupců (`features`) našich dat. Tyto popisky zázkáme od `encoder` , který s nimi manipuloval. Slouží k tomu metoda `get_feature_names_out()` , kterou jsme si už ukazovali. Výsledek volání metody přidáme jako parametr `feature_names` funkci `export_graphviz`

export_graphviz .

In [94]:
```
dot_data = StringIO()
export_graphviz(clf, out_file=dot_data, filled=True, feature_names=encoder.ge
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
Image(graph.create_png())
```

Out[94]:

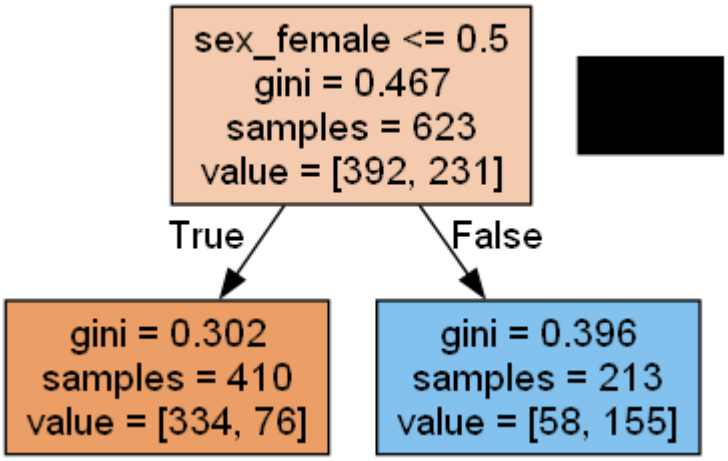

In [95]:
```
clf.classes_
```

Out[95]:
```
array([0, 1], dtype=int64)
```

In [96]:
```
classes = ["Died", "Survied"]
```

Nyní již vidíme, že v kořenu je `sex_female` (případně tam může být `sex_male`, oba dva sloupce poskytují stejnou informaci). Pokud je v tomto sloupci 0, pak je pasažér muž, pokud je ve sloupci 1, pak je pasažér žena. My bychom chtěli klasifikovat muže, vybíráme tedy variantu `True` (tj. je pravda, že ve sloupci `sex_female` by měl pasažér 0). Další vrchol je list, protože nemá potomky. Nyní musíme provést rozhodnutí, do jaké skupiny pasažéra zařadit. Ve druhém řádku listu vidíme, že mužů bylo v trénovacích datech `406` a v posledním řádku dále vidíme `value = [339, 67]`. To jsou počty pozorování dle hodnot výstupní proměnné. Hodnotu 0 výstupní proměnné má 339 (pomět mužů, kteří zahynuli) a hodnotu 1 výstupní proměnné má 67 (počet mužů, kteří přežili). Muže bychom tedy zařadili do skupiny těch, kteří nepřežili.

Přehlednost zobrazení zvýší, pokud doplníme parametr `class_names`. Pak uvidíme třídu, kterou rozhodovací strom predikuje, v posledním řádku.

In [97]:
```
dot_data = StringIO()
export_graphviz(clf, out_file=dot_data, filled=True, feature_names=encoder.ge
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
Image(graph.create_png())
```

Out[97]:

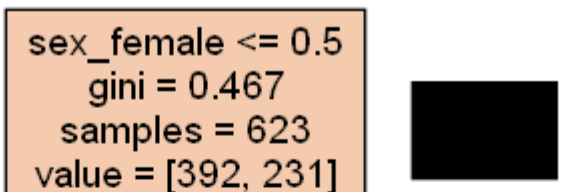

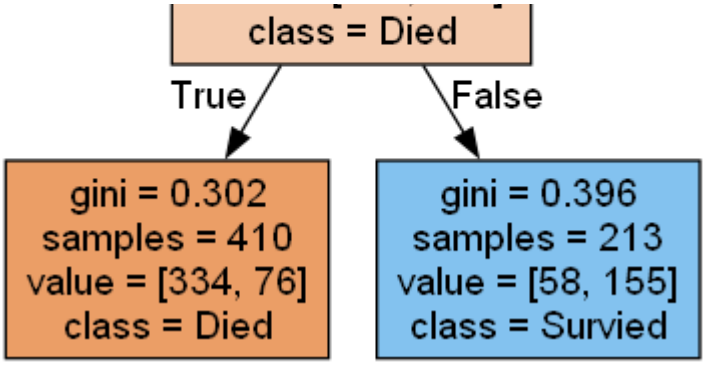

Čtení na doma - gini

Pokud máme v datech více různých sloupců, modul `scikit-learn` se musí nějak rozhodnout, jak strom vytvořit. Jednou z možností, jak vybrat vhodný sloupec, je koeficient `gini`. Ten je jakýmsi měřítkem "různorodosti" dat v daném uzlu. Například v jednom vrcholu je 334 zemřelých a 76 přeživších a ve druhém vrcholu je 58 zemřelých a 155 přeživších. V jednom z vrcholů tedy v početnější skupině relativně více pozorování než v té méně početné, proto je koeficient gini pro tento rozhodovací vrchol menší.

$$gini = 1 - \sum(\pi_k^2)$$

π_k je pravděpodobnost, že pozorování patří do skupiny k. Vypočítáme ji tak, že vydělíme počet pozorování ve skupině k celkovým počtem pozorování v celém uzlu. Například počet zemřelých v pravém uzlu je 334 a celkový počet pozorování je 410, pravděpodobnost $\pi = \frac{334}{410} = 0.8146$ (tj. v trénovacím vzorku máme 81.46 % mrtvých mužů). Pravděpodobnost pak umocníme na druhou. Stejný výpočet provedeme pro všechny skupiny, výsledky sečteme a odečteme od 1.

Níže je příklad výpočtu pro pravý list.

In [98]:
```
334/410
```

Out[98]:
```
0.8146341463414634
```

In [99]:
```
1 - ((334/410) ** 2 + (76/410) ** 2)
```

Out[99]:
```
0.30201070791195717
```

Je možné se podle takového koeficientu rozhodnout? Uvažujme, že bychom získali list, kde jsou obě skupiny zastoupeny rovnoměrně, tj. máme 203 přeživších a 203 zemřelých. Takové dělení by bylo k ničemu, protože se z něj nic nedozvíme. Nebudeme umět přiřadit pozorování do žádné skupiny.

In [100…
```
1 - ((203/406) ** 2 + (203/406) ** 2)
```

Out[100…
```
0.5
```

Pokud bychom naopak měli všechna pozorování v jedné skupině, je takové dělení ideální, protože nám jasně oddělilo obě skupiny. V takovém případě by byl gini

ideální, protože nám jasně oddělilo obě skupiny. V takovém případě by byl gini koeficient 0.

In [101…

```
1 - ((406/406) ** 2 + (0/406) ** 2)
```

Out[101…

```
0.0
```

Strom tedy budeme vykreslovat tak, abychom dosáhli co nejnižšího gini koeficientu, což nám zajistí, že rozdíl mezi oběma skupinami bude co největší.

Přidání dalších sloupců

Nyní do stromu přidáme další proměnnou, pomocí které bude strom predikovat, a to třída, ve které každá z osob cestovala. Vidíme, že strom se docela rozrostl.

In [102…

```
feature_cols = ["sex", "class"]

X = data[feature_cols]
y = data["survived"]

encoder = OneHotEncoder()
X = encoder.fit_transform(X)

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, rand

clf = DecisionTreeClassifier()
clf = clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)


dot_data = StringIO()
export_graphviz(clf, out_file=dot_data, filled=True, feature_names=encoder.ge
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
Image(graph.create_png())
```

Out[102…

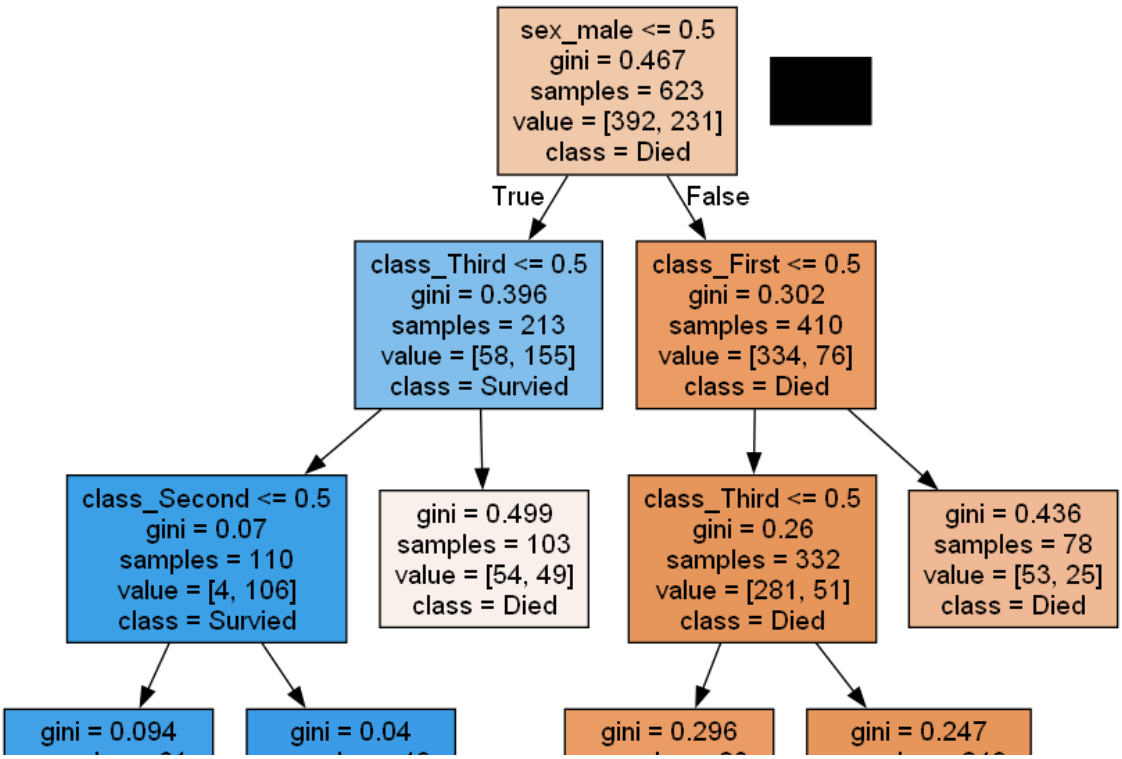

U rozhodovacího stromu můžeme, podobně jako u ostatních algoritmů, nastavovat parametry. U rozhodovacího stromu můžeme měnit tyto:

- `max_depth` = hloubka stromu ("počet pater" stromu),
- `min_samples_split` = minimální počet vzorků pro rozdělení (pokud bude mít vrchol méně, nepůjde dále rozdělit a stane se listem).

Proč tyto parametry řešit?

Výchozí hodnota parametru `max_depth` je `None`, což znamená, že neexistuje žádný limit výška stromu. Strom tak může být velmi komplexní a může vyústit v problém označovaný jako **overfitting** (lze volně přeložit jako "přeučení"). Overfitting je běžný problém v strojovém učení, který nastává, pokud se model příliš dobře přízpůsobí trénovacím datům. To vede k tomu, že model je nedostatečně schopen generalizovat na nová, dosud neviděná data. Overfitting se často projevuje tím, že model má vysokou přesnost na tréninkových datech, ale nízkou přesnost na testovacích datech. Nastavení maximální výšky stromu omezí komplexnost stromu a též může snížit overfitting, protože klasifikace je pak založena na menší kombinaci hodnot jednotlivých sloupců.

Overfitting může omezit též `min_samples_split`, protože brání tomu, aby bylo rozhodnutí činěno na příliš malém množství pozorování. Rozhodnutí založené na jednotkách pozorování může být navázána na příliš specifické vlastnosti trénovací sady dat.

Nejprve zkusíme omezit výšku stromu na 2.

In [103…

```
feature_cols = ["sex", "class"]

X = data[feature_cols]
y = data["survived"]

encoder = OneHotEncoder()
X = encoder.fit_transform(X)

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, rand

# Strom může mít maximálně 2 patra (kořen nepočítáme)
clf = DecisionTreeClassifier(max_depth=2)
clf = clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)


dot_data = StringIO()
export_graphviz(clf, out_file=dot_data, filled=True, feature_names=encoder.ge
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
Image(graph.create_png())
```

Out[103…

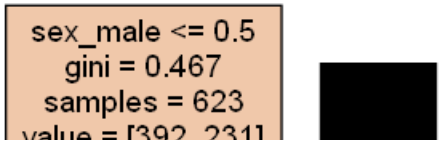

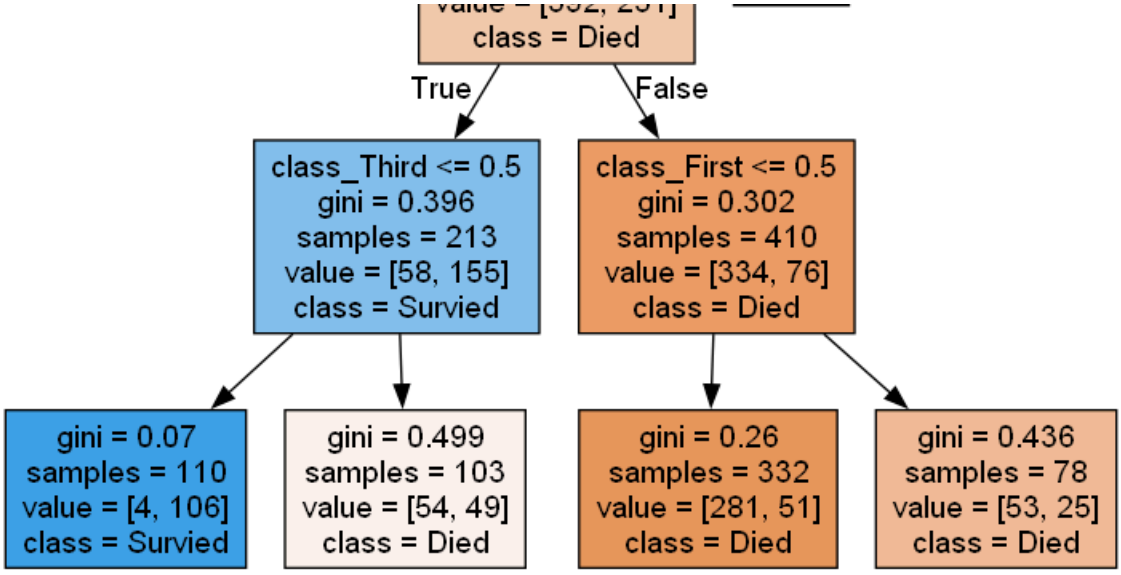

Následně zkusíme omezit dělení vrcholů na vrcholy o minimálním počtu 40 pozorování.

In [104…

```
feature_cols = ["sex", "class"]

X = data[feature_cols]
y = data["survived"]

encoder = OneHotEncoder()
X = encoder.fit_transform(X)

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, rand

# Uzly s méně než 100 vzorky již nejdou rozdělit
clf = DecisionTreeClassifier(min_samples_split=40)
clf = clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)


dot_data = StringIO()
export_graphviz(clf, out_file=dot_data, filled=True, feature_names=encoder.ge
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
Image(graph.create_png())
```

Out[104…

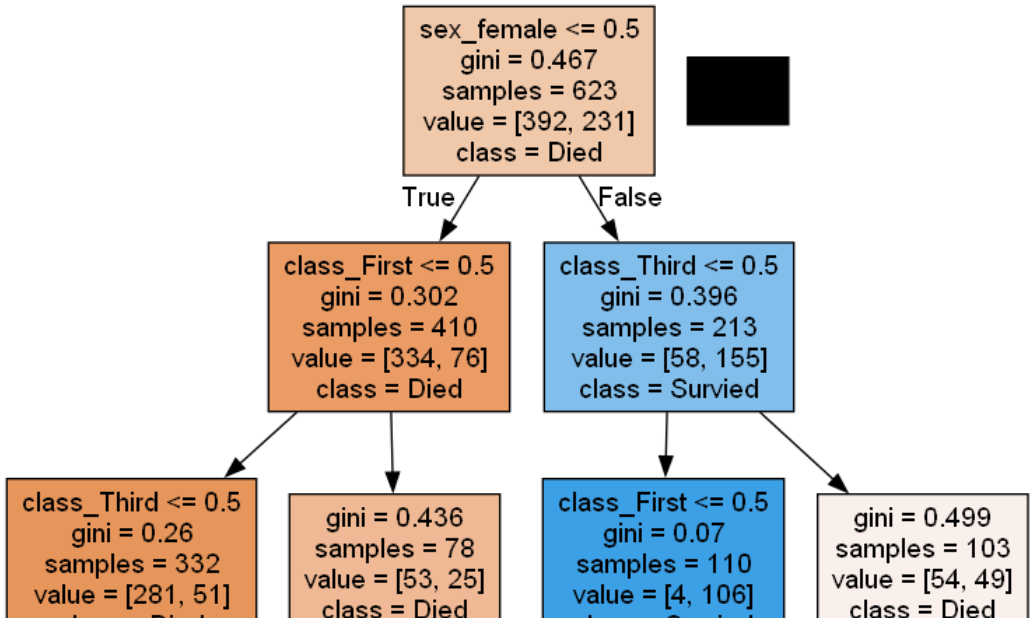

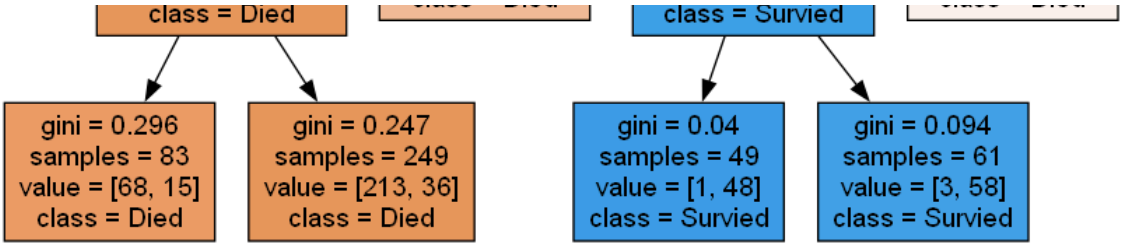

Přidání zbylých proměnných

Nyní přidáme další proměnné. Budeme se držet čistě kategoriálních proměnných. Namísto `sex` použijeme `who`, což je sloupec, který rozděluje osoby na muže, ženy a děti. Strom, který tento kód vygeneruje, je opravdu gigantický a určitě by se nám jen nepovedlo například rozumně vytisknout na stránku o velikosti A4. To ale nevadí, řada komplexních dat vede ke komplexnímu rozhodovacímu stromu. Pokud potřebujeme strom menší (např. aby byl více přehledný), můžeme použít parametry, které jsme si ukazovali výše.

- `sibsp` - Celkový počet sourozenců a manželek/manželů, kteří spolu s pasažérem cestovali.
- `parch` - Celkový počet dětí a rodičů, kteří spolu s pasažérem cestovali.
- `embarked` - Přístav, kde pasažérk(ka) nastoupil(a), C = Cherbourg, Q = Queenstown, S = Southampton.
- `who` - Rozdělení na muže, ženy a děti.
- `alone` - Zda cestující cestoval(a) sám/sama.

In [105…

```
feature_cols = ["sibsp", "parch", "embarked", "class", "who", "alone"]

X = data[feature_cols]
y = data["survived"]

encoder = OneHotEncoder()
X = encoder.fit_transform(X)

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, rand

clf = DecisionTreeClassifier()
clf = clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)

dot_data = StringIO()
export_graphviz(clf, out_file=dot_data, filled=True, feature_names=encoder.ge
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
Image(graph.create_png())
```

Out[105…

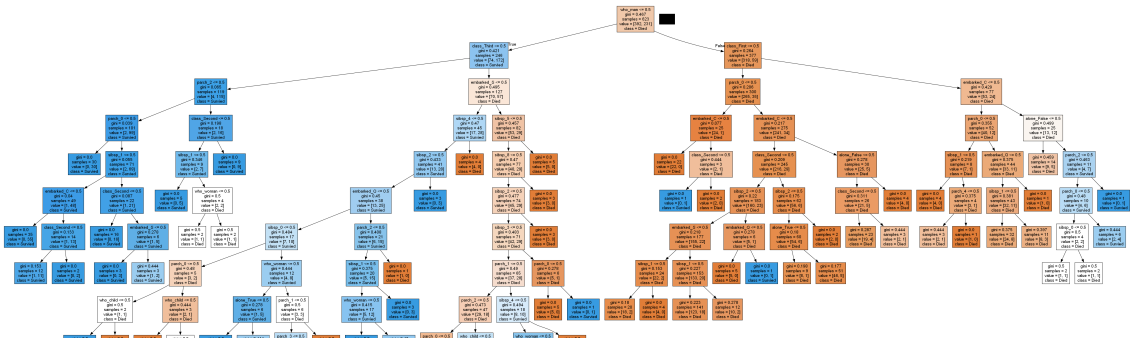

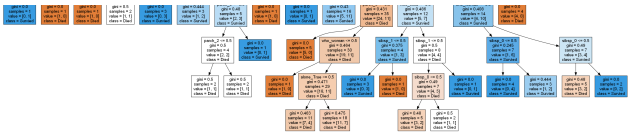

Kvalitu predikcí takto gigantického stromu můžeme ověřit pomocí matice záměn, která má stejnou strukturu a stejnou interpretaci jako v předchozích lekcí.

In [106…
```
ConfusionMatrixDisplay.from_estimator(clf, X_test, y_test)
```

Out[106…
```
<sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at 0x220331eb310>
```

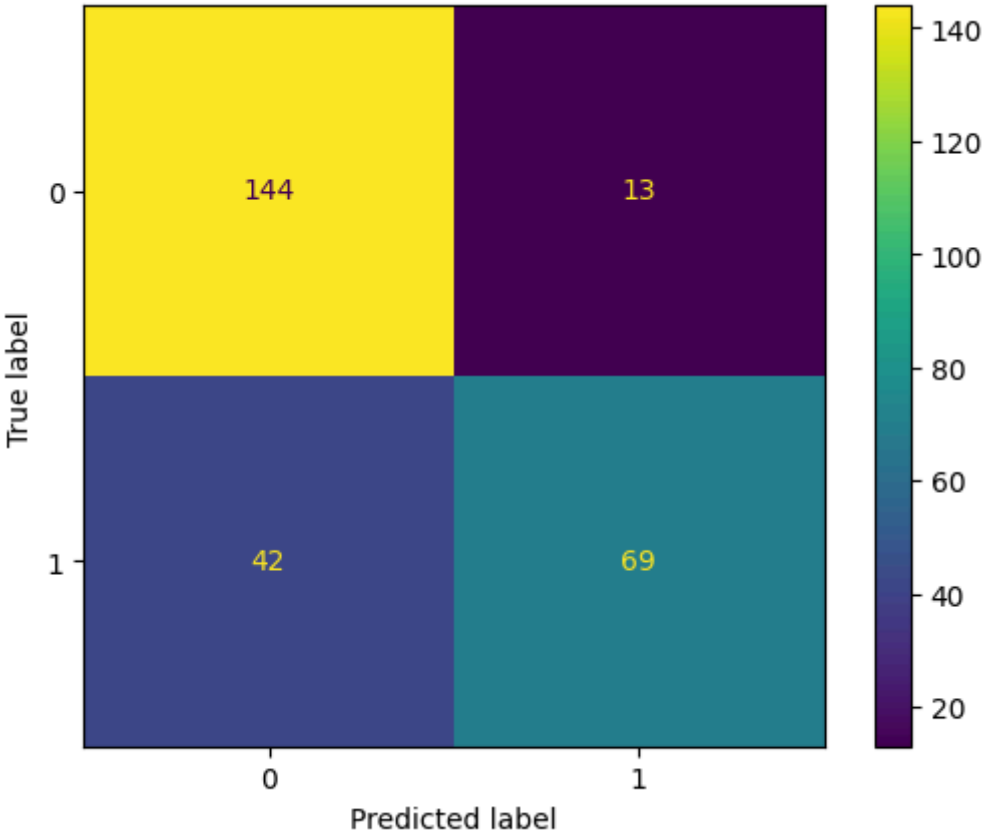

Též můžeme spočítat všechny metriky, které jsme si již ukázali.

In [107…
```
accuracy_score(y_test, y_pred)
```

Out[107…
```
0.7947761194029851
```

In [108…
```
precision_score(y_test, y_pred)
```

Out[108…
```
0.8414634146341463
```

In [109…
```
recall_score(y_test, y_pred)
```

Out[109…
```
0.6216216216216216
```

Kombinace číselných a kategoriálních proměnných

V našem datasetu máme i numerický sloupec, který označuje cenu jízdenky. Na tento

údaj nepotřebujeme použít `OneHotEncoder()`. Proto vytvoříme dva seznamy sloupců:

- `categorical_columns`, kam uložíme sloupce s kategorickými hodnotami,
- `numeric_columns`, kam uložíme sloupce (resp. sloupec) s numerickými hodnotami.

In [110…
```
import numpy

y = data["survived"]

categorical_columns = ["embarked", "class", "who", "alone"]
numeric_columns = ["fare", "sibsp", "parch"]
```

Z tabulky `data` vybereme sloupce v seznamu `others` a převedeme je na pole s využitím metody `to_numpy()`.

In [111…
```
others = data[numeric_columns].to_numpy()
```

Následně sloupce v seznamu `categorical_columns` upravíme pomocí `OneHotEncoder`.

Je to trochu nešťastné, ale metody na převod na matici se jmenují v modulech `scikit-learn` a `pandas` různě.

- V modulu `scikit-learn` používáme metodu `to_numpy()`
- V modulu `pandas` používáme metodu `toarray()`.

In [112…
```
ohe = OneHotEncoder()
encoded_columns = ohe.fit_transform(data[categorical_columns])
encoded_columns = encoded_columns.toarray()
```

In [113…
```
type(others)
```

Out[113… `numpy.ndarray`

In [114…
```
type(X)
```

Out[114… `scipy.sparse._csr.csr_matrix`

Nakonec obě pole spojíme do jednoho pomocí funkce `numpy.concatenate()`. Tato funkce je jakousi "hloupější" verzí funkce `merge()`, kterou známe z `pandas`. Spojuje dvě matice do jedné na základě čísla řádků, tj. vezme nultý řádek z obou polí a vytvoří z něj jeden dlouhý řádek v nové matici, to samé s prvním řádkem atd.

In [115…
```
X = numpy.concatenate([encoded_columns, others], axis=1)
```

Na konci data opět rozdělíme na trénovací a testovací.

In [116…

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, rand

clf = DecisionTreeClassifier()
clf = clf.fit(X_train, y_train)
y_pred = clf.predict(X_test)
```

Výsledky rozhodovacího stromu můžeme zobrazit pomocí matice záměn. Ta funguje stejně jako u předchozích algoritmů.

In [117…

```
ConfusionMatrixDisplay.from_estimator(clf, X_test, y_test)
```

Out[117…

```
<sklearn.metrics._plot.confusion_matrix.ConfusionMatrixDisplay at 0x220325750
d0>
```

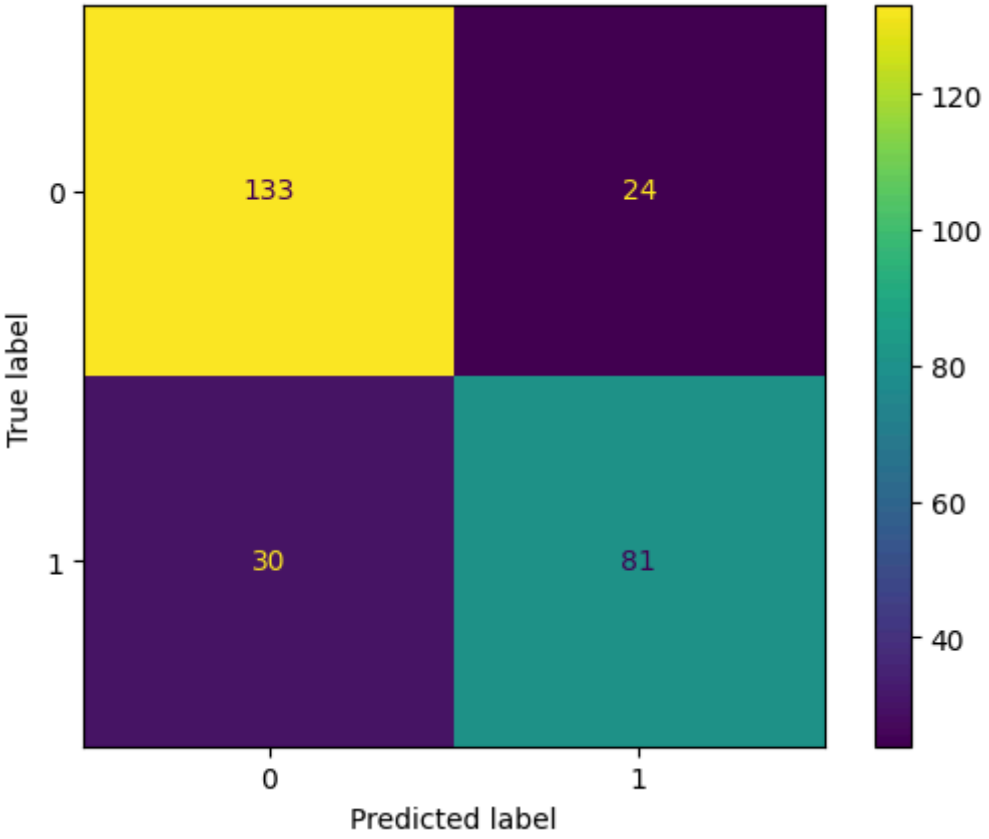

Podobně můžeme určitě i metriky modelu.

In [118…

```
accuracy_score(y_test, y_pred)
```

Out[118…

```
0.7985074626865671
```

In [119…

```
precision_score(y_test, y_pred)
```

Out[119…

```
0.7714285714285715
```

In [120…

```
recall_score(y_test, y_pred)
```

Out[120…

```
0.7297297297297297
```

Hledání nejlepší parametrů

Hledání nejlepší parametru

Ke hledání nejlepší parametrů opět využijeme `GridSearchCV`

In [121…

```
model = DecisionTreeClassifier()
params = {"max_depth": [3, 4, 5, 6, 7, 8, 9, 10], "min_samples_split": [10, 2

clf = GridSearchCV(model, {"max_depth": [3, 4, 5]}, scoring="accuracy")
clf.fit(X, y)

print(clf.best_params_)
print(clf.best_score_)
```

```
{'max_depth': 4}
0.8271483271608814
```

Zdroje

- Decision Tree Classifier with Sklearn in Python
- Decision Tree Classification in Python Tutorial
- How to tune a Decision Tree?
- Overfitting and Pruning in Decision Trees — Improving Model's Accuracy
- 3 Techniques to Avoid Overfitting of Decision Trees (v placené části)

Cvičení

Rezervace

Vyzkoušej rozhodovací strom na datové sadě o rezervací hotelů ze serveru Booking.com (hotel_bookings.csv), kterou jsme používali na začátku kurzu.

- Podívej se, kolik je v datech zrušených rezervací a kolik nezrušených.
- V prvním kroku zkus sestavit pouze na základě proměnné `lead_time`, u které bychom (na základě grafů z první lekce) se mohli domnívat, že bude mít vliv na to, jestli bude rezervace zrušená. Omez strop na `max_depth=2`. Nech si graficky zobrazit strom a na základě obrázku odhadni, jestli bude zrušená rezervace udělaná 5, 20, 100 a 300 dní.
- Vytvoř si pro tento strom matici záměn a urči hodnotu metriky `accuracy`.
- Na rozdíl od například datasetu o kostatcích není tento dataset perfektně vyvážený. V realitě se často setkáváme s tzv. nevyváženými datasety (*imbalanced dataset*), kde je dat z jedné skupiny výrazně víc než dat z druhé. Příkladem jsou například podvodné transakce (podvodných transakcí je mnohem méně než těch běžných), kybernetické útoky (útoků je mnohem méně než běžného provozu v síti) atd. V takových případech nemusí být metrika `accuracy` úplně vhodná. Vyzkoušej proto metriku `balanced_accuracy_score`. Níže je popsaný import.

```
from sklearn.metrics import balanced_accuracy_score
```

- Problém s nevyváženými datasety je, že modelu stačí správně zařadit dostatečné

množství hodnot z početnější skupiny. Protože dat v menší skupině je celkově méně, malá úspěšnost v jejich správné identifikaci sníží metriku `accuracy` jen málo. Naopak `balanced_accuracy_score` uvažuje množství dat v jednotlivých skupinách. Méně početné skupiny mají větší váhu, model je tím pádem nucen soustředit se i na ně. Zkus zjistit hodnotu metriky `balanced_accuracy_score`. Funkce se používá stejně jako `accuracy`.

Bonusy k rezervacím

Nyní do modelu přidej i další sloupce:

- kategorické sloupce: country, market_segment, distribution_channel, arrival_date_month, meal
- číselné sloupce: lead_time, stays_in_weekend_nights, stays_in_week_nights, adults, children, babies, is_repeated_guest, previous_cancellations, previous_bookings_not_canceled

Nyní vyzkoušej `GridSearchCV` a najdi optimální hodnotu parametru `min_samples_split` pro možné parametry `[10, 20, 30, 40]`, pro hodnocení použij metriku `accuracy`.

Video s řešením je zde.

Nápověda

Takto můžeš vytvořit matici s daty.

```
categorical_columns = ["country", "market_segment",
"distribution_channel", "arrival_date_month", "meal"]
numeric_columns = ["lead_time", "stays_in_weekend_nights",
"stays_in_week_nights", "adults", "children", "babies",
"is_repeated_guest", "previous_cancellations",
"previous_bookings_not_canceled"]

# Převod na pole - numpy
others = data[numeric_columns].to_numpy()
ohe = OneHotEncoder()
# Použití OneHotEncoder - "vyrobí" číselné sloupečky z textových
sloupečků
encoded_columns = ohe.fit_transform(data[categorical_columns])
# Převedeme data na pole
encoded_columns = encoded_columns.toarray()
# Spojíme obě pole dohromady - chceme mít zase všechna data
pohromadě
X = np.concatenate([encoded_columns, others], axis=1)
```

Bonus: Poruchy

Vrať se k datům o poruchách ze souboru predictive_maintenance.csv a pokus se pomocí rozhodovacího stromu klasifikovat stavy stroje.

Použij sloupce Type, Air temperature [K], Process temperature [K], Rotational speed

[rpm], Torque [Nm], Tool wear [min] jako vstupní proměnné a Failure Type jako výstupní proměnnou. Sloupec `Type` obsahuje kategoriální hodnoty, použij teddy `OneHotEncoder`.

Sestav strom, který bude predikovat hodnotu sloupce `Failure Type` - tj. to, jestli dojde k selhání a případně k jakému. Omez hloubku stromu na 5, aby byl strom stále celkem přehledný a mohl být například vložen do servisního manuálu.

Níže máš připravené seznamy sloupců, názvy proměnných odpovídají tomu, co jsme používali v lekci.

```
categorical_columns = ["Type"]
numeric_columns = ["Air temperature [K]", "Process temperature [K]",
"Rotational speed [rpm]", "Torque [Nm]", "Tool wear [min]"]
```

Nápověda

Pokud bys chtěl(a) do stromu přidat i názvy features, je to trochu složitější. Je třeba spojit názvy sloupců, které vzešly z `OneHotEncoder`, a názvy numerických sloupců, které jsou původní. Níže je kód který toto provede.

```
feature_names = list(ohe.get_feature_names_out()) +
list(numeric_columns)
feature_names
```

Níže je příklad toho, jak potom použít proměnnou `feature_names` při generování stromu.

```
dot_data = StringIO()
export_graphviz(clf, out_file=dot_data, filled=True,
class_names=clf.classes_, feature_names=feature_names)
graph = pydotplus.graph_from_dot_data(dot_data.getvalue())
Image(graph.create_png())
```

Video s řešením je zde. Text k oběma příkladům je zde.

Další zdroje k imballanced datasetům

-
-